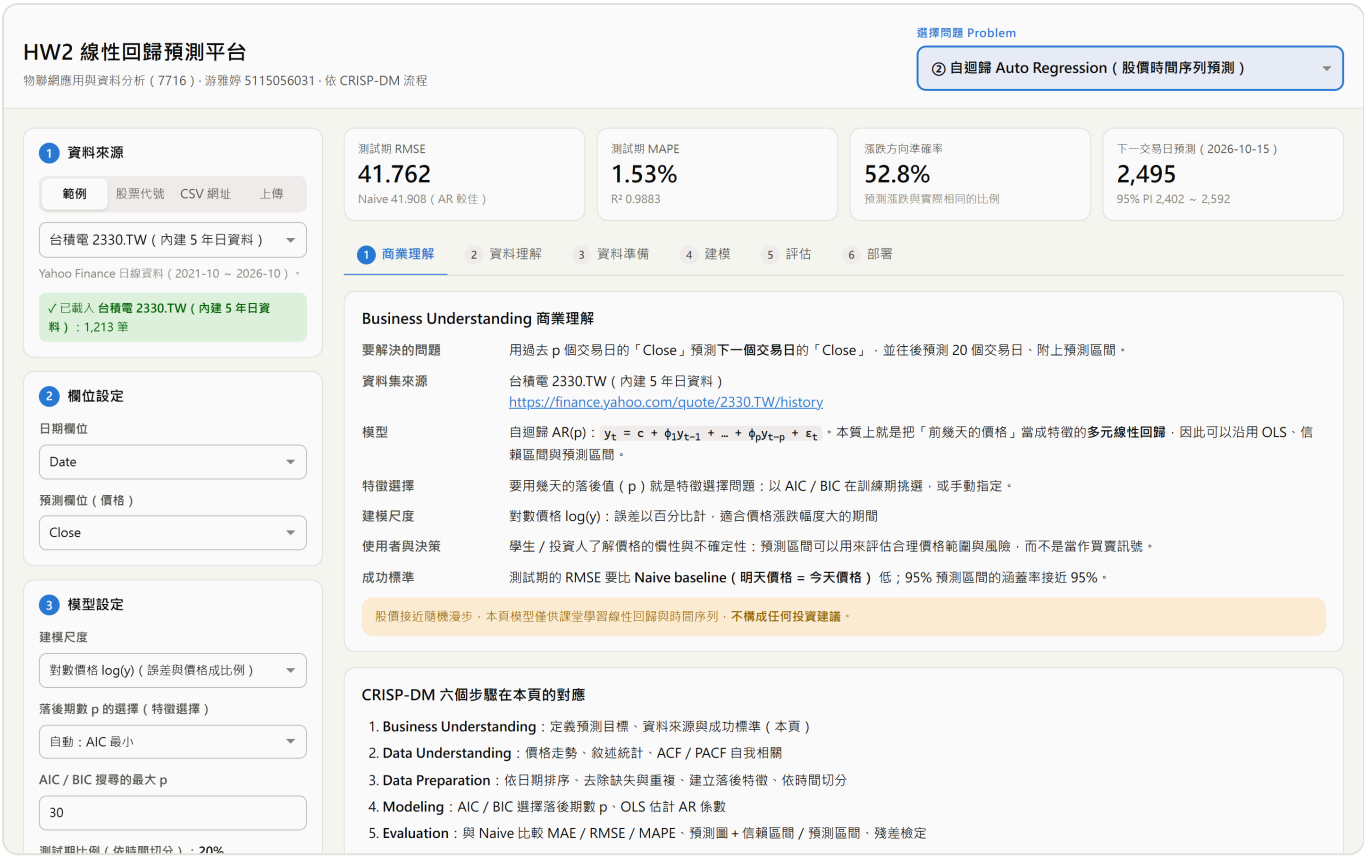
HW2：MULTIPLE LINEAR REGRESSION

線性回歸預測平台 報告書
自迴歸（Auto Regression）股價預測

依 CRISP-DM 流程｜互動網頁：下拉選單切換兩種問題、使用者可自行更換資料來源



課程：物聯網應用與資料分析（7716）

學生：游雅婷　學號：5115056031

網頁：https://aiot-hw2-regression.vercel.app（GitHub Pages：https://jua91352.github.io/AIoT-HW2-Regression/）

原始碼：https://github.com/jua91352/AIoT-HW2-Regression

日期：2026-10-22

摘要

本作業製作一個可直接部署的互動式線性回歸預測平台：頁首下拉選單可切換「① 多元線性回歸」與「② 自迴歸 Auto Regression」兩種問題，使用者可用範例資料、股票代號、任意 CSV 網址或上傳檔案更換資料來源，所有統計計算都在瀏覽器中完成，並部署於 Vercel 與 GitHub Pages。

本報告以問題 ② 為主：以台積電（2330.TW）1,213 個交易日的收盤價，依 CRISP-DM 建立 AR(p) 模型。以 AIC / BIC 選擇落後期數（特徵選擇）得到 AR(1)，估計係數 $\varphi_1 = 1.0006$，顯示股價接近隨機漫步。測試期（2025-10-14 ~ 2026-10-14，243 天）一步預測 RMSE = 41.762，略優於 Naive 基準的 41.908；改用對數價格建模後，95% 預測區間的實際涵蓋率從 63.8% 提升到 94.2%。

目錄

1. 作業需求對照
2. 平台概觀
3. CRISP-DM：自迴歸股價預測（主體）
4. 可任意輸入資料（加分項）
5. 問題 ①：多元線性回歸（簡述）
6. 主流解法比較
7. NotebookLM 摘要
8. GPT 輔助內容
9. 數值正確性驗證
10. 結論與限制

一、作業需求對照

作業要求	本作業的做法	報告位置
加分 +1：下拉視窗呈現兩種 problem	頁首「選擇問題 Problem」：① 多元線性回歸、② 自迴歸 Auto Regression	第二章、圖 1
加分 +2：可任意輸入 Dataset	範例資料 / 股票代號 / 任意 CSV 網址 / 上傳檔案；50_Startups 網址實測	第四章
線性回歸：單純、多元或 Auto Regression	主體為 AR(p)（以落後值為特徵的多元線性回歸）；問題 ① 為 MLR	第三章、第五章
Kaggle 資料集、特徵 > 13、標示來源	問題 ①：Kaggle Predict the Flood，20 個特徵，附連結	第五章
特徵選擇 Feature Selection	AR：以 AIC / BIC 選擇落後期數 p；MLR：4 種方法 + CV	3.4 節
模型評估 Model Evaluation	MAE、MSE、RMSE、MAPE、R^2、方向準確率、Ljung-Box；與 Naive 比較	3.5 節
預測圖 + 信賴區間或預測區間	測試期一步預測 + 95% CI / PI；未來 20 日預測 + 95% PI	圖 13、14、18
CRISP-DM 六步驟	網頁六個分頁；本報告第三章逐步說明	第三章
GitHub + web	https://github.com/jua91352/AIoT-HW2-Regression https://aiot-hw2-regression.vercel.app	3.6 節
NotebookLM 摘要、GPT 輔助內容	股價預測摘要（第七章）、洪水預測摘要（5.1 節）；GPT 輔助內容（第八章）；AI 對話紀錄 PDF 另行上傳	第七、八章、5.1 節

二、平台概觀

網頁分成三個區塊：頁首右側是**問題下拉選單**；左側是資料來源、欄位設定、模型設定；主畫面依 CRISP-DM 分成六個分頁，最上方的指標卡顯示測試期 RMSE、MAPE、漲跌方向準確率與下一交易日預測。

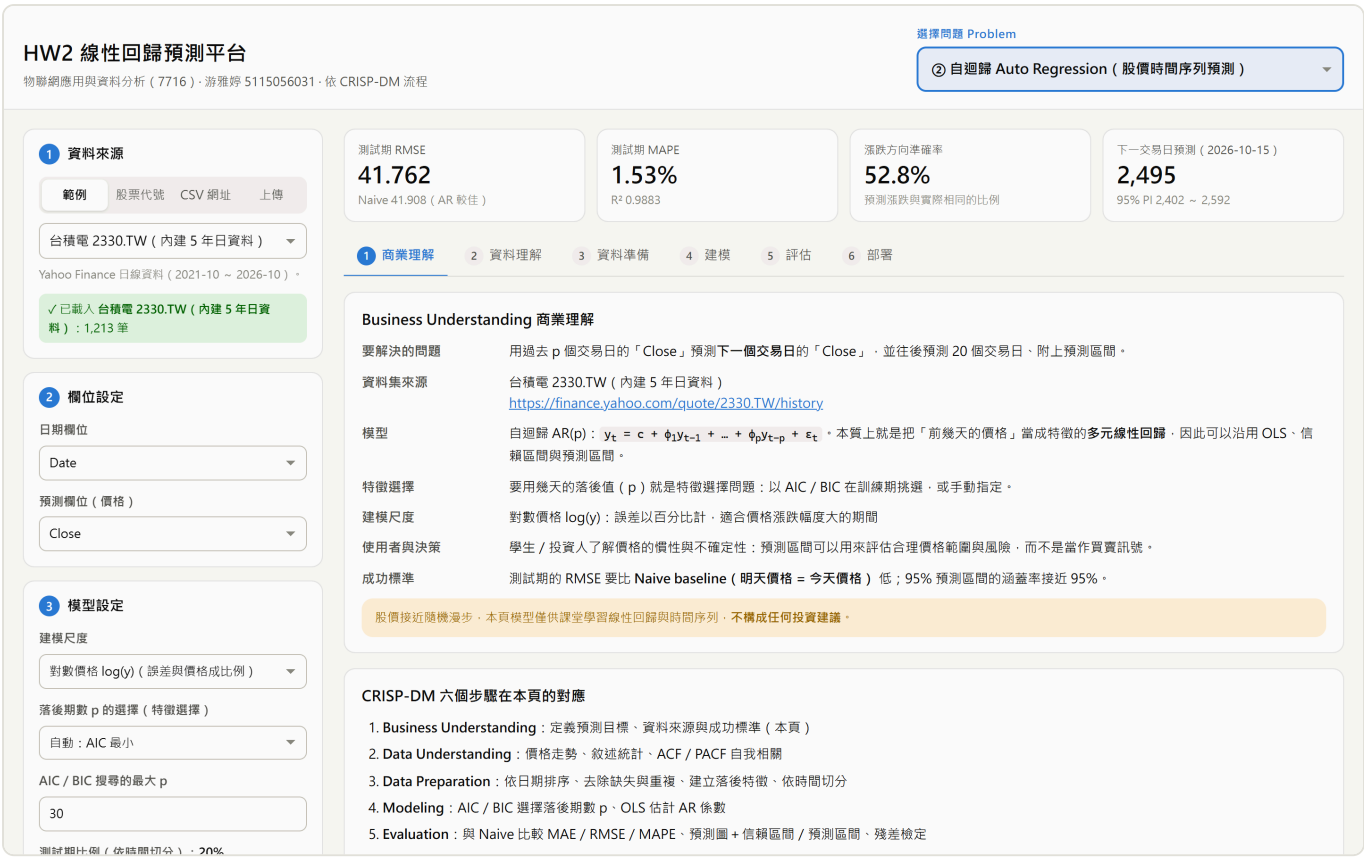


圖 1　問題 ② 自迴歸的首頁：頁首下拉選單切換兩種問題、左側可更換資料來源

多元線性回歸（問題 ①）已於 DIC2 繳交過一個版本，本報告只在第五章簡述，主體為自迴歸。

三、CRISP-DM：自迴歸股價預測

3.1 Business Understanding 商業理解

- **問題**：用過去 p 個交易日的收盤價，預測下一個交易日的收盤價，並往後預測 20 個交易日、附上預測區間。
- **模型**：自迴歸 AR(p)：$y_t = c + \varphi_1 y_{t-1} + \dots + \varphi_p y_{t-p} + \varepsilon_t$。本質上是把「前幾天的價格」當成特徵的多元線性回歸，因此可以沿用 OLS、信賴區間與預測區間。
- **使用者與決策**：學生與投資人了解價格的慣性與不確定性；預測區間用來評估合理價格範圍與風險，而不是買賣訊號。
- **成功標準**：測試期 RMSE 低於 Naive 基準（明天價格 = 今天價格）；95% 預測區間的實際涵蓋率接近 95%。



Business Understanding 商業理解

要解決的問題	用過去 p 個交易日的「Close」預測**下一個交易日**的「Close」，並往後預測 20 個交易日、附上預測區間。
資料集來源	台積電 2330.TW（內建 5 年日資料） https://finance.yahoo.com/quote/2330.TW/history
模型	自迴歸 AR(p)：$y_t = c + \phi_1 y_{t-1} + \dots + \phi_p y_{t-p} + \varepsilon_t$。本質上就是把「前幾天的價格」當成特徵的**多元線性回歸**，因此可以沿用 OLS、信賴區間與預測區間。
特徵選擇	要用幾天的落後值（p）就是特徵選擇問題：以 AIC / BIC 在訓練期挑選，或手動指定。
建模尺度	對數價格 log(y)：誤差以百分比計，適合價格漲跌幅度大的期間
使用者與決策	學生 / 投資人了解價格的慣性與不確定性：預測區間可以用來評估合理價格範圍與風險，而不是當作買賣訊號。
成功標準	測試期的 RMSE 要比 **Naive baseline（明天價格 = 今天價格）** 低；95% 預測區間的涵蓋率接近 95%。

股價接近隨機漫步，本頁模型僅供課堂學習線性回歸與時間序列，**不構成任何投資建議**。

圖 2　網頁「商業理解」分頁

3.2 Data Understanding 資料理解

- **資料來源**：Yahoo Finance 台積電 2330.TW 日線資料（finance.yahoo.com/quote/2330.TW），由本平台的 `/api/stock` 下載並內建於網站。
- **期間**：2021-10-14 ~ 2026-10-14，共 1,213 個交易日；欄位為 Date、Open、High、Low、Close、Adj Close、Volume，預測目標為 Close。
- **走勢**：收盤價從 573 元漲到 2,490 元；測試期第一天為 1,425 元，測試期內上漲約 75%。
- **自我相關**：ACF 緩慢遞減、PACF 在第 1 期之後落入信賴界線內 → 價格具強烈慣性且非定態，適合從 AR(1) 開始建模。



圖 3　台積電收盤價 K 線圖（紅漲綠跌，可拖曳縮放）

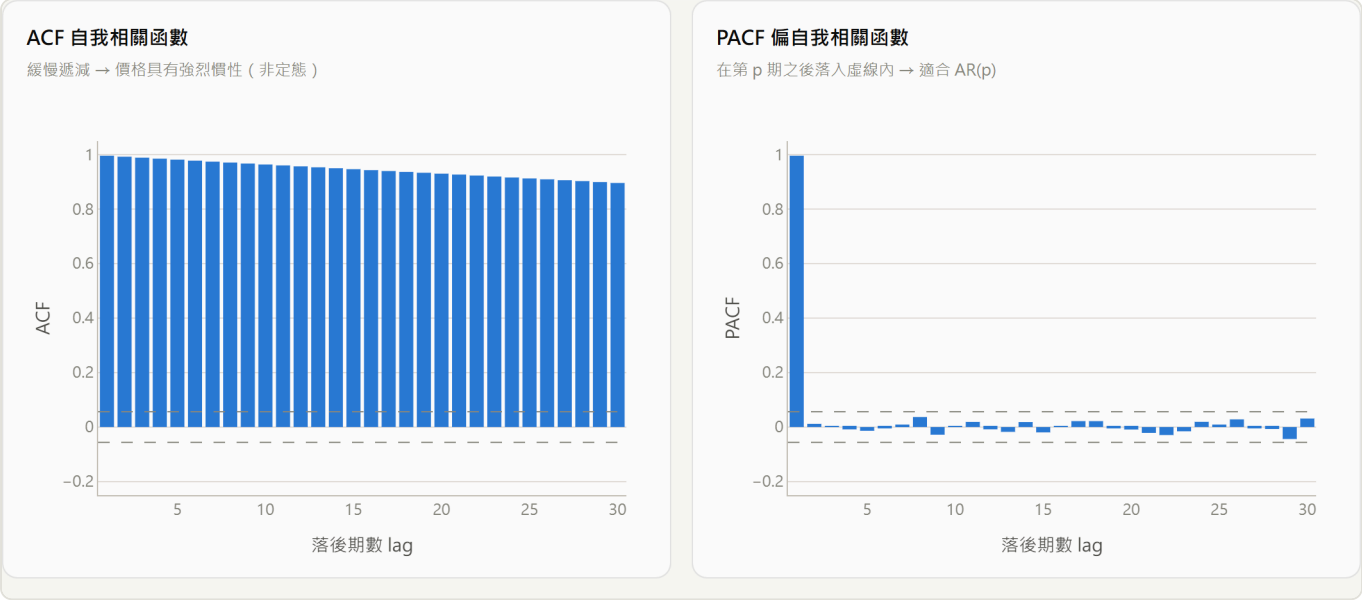
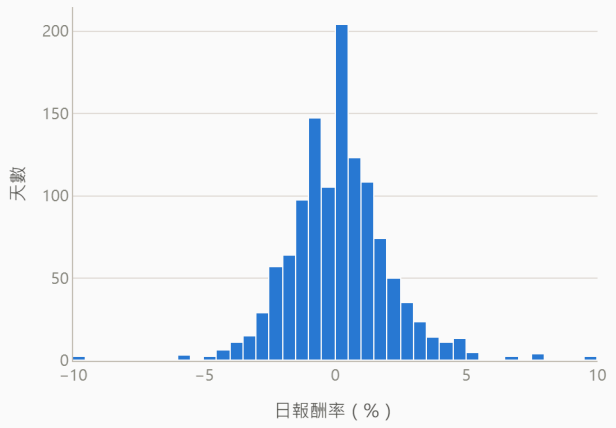


圖 4　ACF 與 PACF：ACF 緩慢遞減、PACF 在 lag 1 截斷

日報酬率分布



最近 10 筆資料

日期	Close
2026-10-14	2,490
2026-10-13	2,490
2026-10-12	2,540
2026-10-08	2,550
2026-10-07	2,585
2026-10-06	2,585
2026-10-05	2,575
2026-10-02	2,500
2026-10-01	2,510
2026-09-30	2,480

圖 5　日報酬率分布與最近 10 筆資料

3.3 Data Preparation 資料準備

1. 解析日期並由舊到新排序；移除缺失與重複日期（本資料皆為 0 筆）。
2. **對數轉換**：以 log(Close) 建模。價格越高、每日波動的金額越大；取對數後誤差變成百分比尺度，變異數較穩定，預測完再以 exp() 轉回價格。
3. **建立落後特徵**：第 t 天的特徵為前 1～p 天的值。
4. **依時間切分、不打亂順序**：訓練期 970 天（2021-10-14 ～ 2025-10-13），測試期 243 天（2025-10-14 ～ 2026-10-14），避免用未來資料預測過去。

Data Preparation 資料準備步驟

1. 以日期欄位「Date」解析日期並**由舊到新排序**。
2. 移除「Close」缺失或無法解析的資料列：0 筆；重複日期（保留最後一筆）：0 筆。剩下 **1,213** 筆。
3. 建立落後特徵：第 t 天的特徵為前 1～1 天的值 y(t−1)…y(t−1)，因此最前面 1 筆沒有完整特徵、不列入訓練。
4. **依時間切分、不打亂順序**（避免用未來資料預測過去）：訓練期 970 筆（2021-10-14 ～ 2025-10-13），測試期 243 筆（2025-10-14 ～ 2026-10-14）。
5. 落後期數 p 的選擇（AIC / BIC）只使用訓練期；測試期採「一步預測」：每天都用真實的前 p 天價格預測隔天。
6. 建模尺度：**對數價格 log(y)**。價格越高、每日波動的金額越大，取 log 後誤差變成「百分比」尺度，變異數較穩定；預測完再以 exp() 轉回價格（因此預測區間上下不對稱）。

圖 6　網頁「資料準備」分頁的步驟說明

落後特徵矩陣（前 6 筆）

日期	y(t) Close	y(t−1)
2021-10-15	600	573
2021-10-18	590	600
2021-10-19	600	590
2021-10-20	598	600
2021-10-21	596	598
2021-10-22	600	596

圖 7　落後特徵矩陣（前 6 筆）

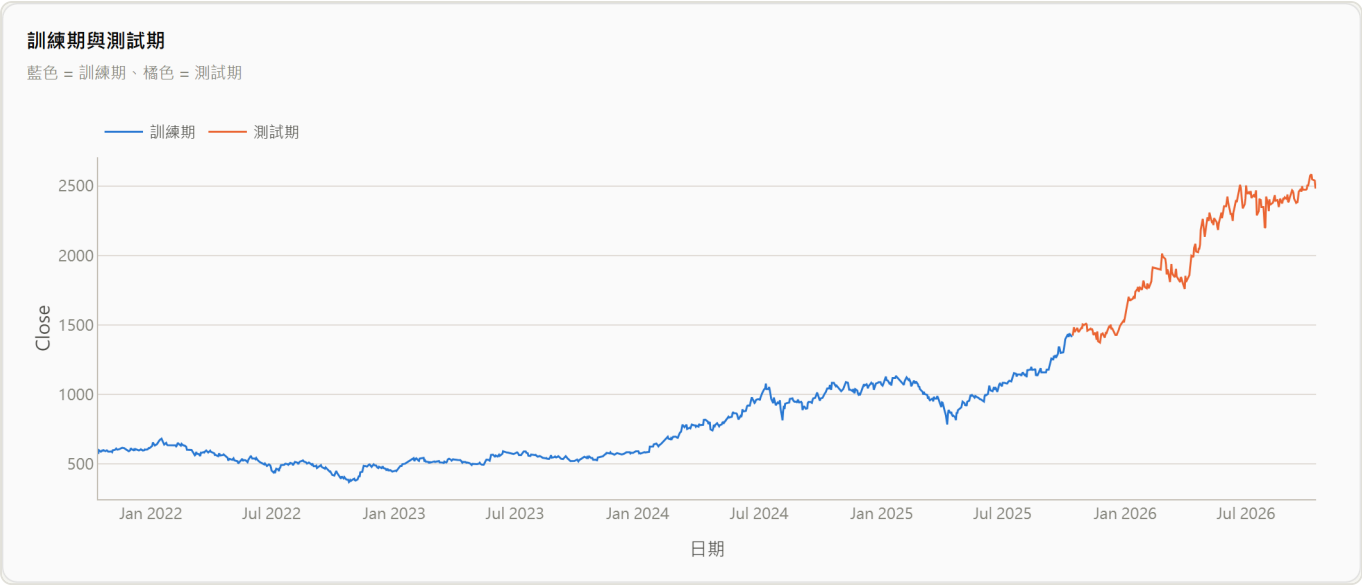


圖 8　訓練期（藍）與測試期（橘）

3.4 Modeling 建模（含特徵選擇）

特徵選擇 = 選擇落後期數 p。在訓練期對 p = 1 ~ 30 分別配適 AR(p)，使用相同的樣本區間比較 AIC 與 BIC。對數尺度下 AIC 與 BIC 都在 **p = 1** 最小；原始價格尺度下 AIC 選 p = 10、BIC 選 p = 1。BIC 懲罰較重、偏好簡單模型；兩種尺度的 BIC 都支持 AR(1)。



圖 9　網頁「建模」分頁：落後期數選擇說明

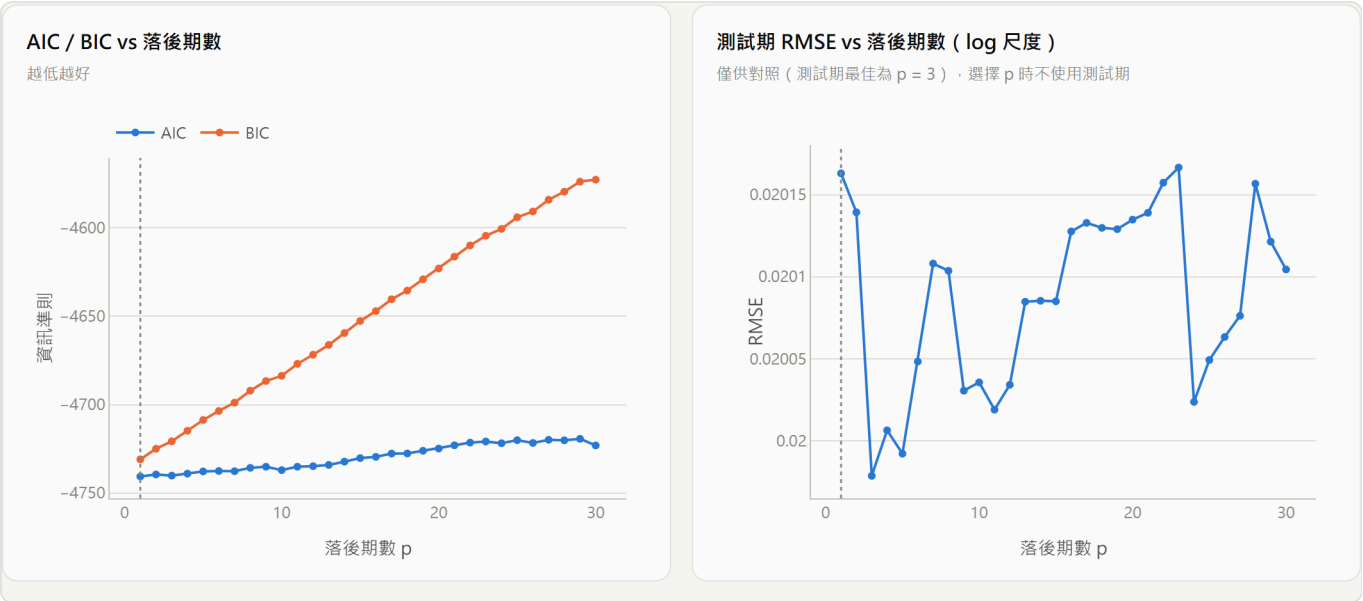


圖 10　AIC / BIC 與測試期 RMSE 隨落後期數的變化

AR(1) 估計結果（訓練期，對數價格）：

變數	係數	標準誤	t 值	p 值	95% CI 下限	95% CI 上限
截距 const	-0.003016	0.012497	-0.24	0.8094	-0.027541	0.021509
log y(t−1)	1.000604	0.001910	523.99	< 1e-16	0.996857	1.004352

$\varphi_1 = 1.0006$（95% CI 0.9969 ~ 1.0044，涵蓋 1），截距不顯著（$p = 0.8094$）。這表示 log 價格幾乎是「昨天的值 + 隨機誤差」，也就是隨機漫步；殘差標準差 $\sigma = 0.0192$，相當於每日約 1.92% 的波動。訓練期 $R^2 = 0.9965$ 很高，是因為價格水準本身的慣性，不代表能預測漲跌。



圖 11　網頁上的 AR 迴歸係數表

3.5 Evaluation 評估

測試期採「一步預測」：每天都用真實的前 p 天價格預測隔天，與 Naive 基準比較，並列出原始價格尺度的 AR(10) 作為對照。

指標	AR(1)，對數價格（採用）	Naive（明天 = 今天）	AR(10)，原始價格
MAE	30.858	30.802	30.395
MSE	1,744	1,756	1,701
RMSE	41.762	41.908	41.247
MAPE	1.53%	1.53%	1.51%
R^2	0.9883	0.9882	0.9886
漲跌方向準確率	52.8%	—	58.5%
95% 預測區間涵蓋率	94.2%	—	63.8%

- **準確度**：AR(1) 的 RMSE 比 Naive 低 0.35%，差距很小，符合「股價接近隨機漫步、難以贏過 Naive」的理論。原始價格的 AR(10) RMSE 略低（41.247），方向準確率 58.5%。
- **不確定性**：原始價格模型的 95% 預測區間只涵蓋 63.8% 的測試期天數——測試期股價從 1,425 漲到 2,490 元，每日波動的金額變大，用早期資料估計的誤差太小。對數價格模型的涵蓋率為 94.2%，接近 95%，因此網頁預設採用對數尺度。

- **殘差檢定**：Ljung-Box（lag 10）Q = 13.65，p = 0.190 > 0.05，殘差近似白噪音，AR(1) 已捕捉到可用的自我相關。

評估指標：AR(1) vs Naive baseline（測試期 243 天，一步預測）

指標	AR(1)	Naive（明天 = 今天）	說明
MAE	30.858	30.802	平均絕對誤差
MSE	1,744	1,756	均方誤差
RMSE	41.762	41.908	與價格同單位
MAPE	1.53%	1.53%	平均絕對百分比誤差
R^2	0.9883	0.9882	價格水準的 R^2 通常很高，需與 Naive 比較才有意義
漲跌方向準確率	52.8%	—	50% 約等於擲硬幣
95% PI 涵蓋率	94.2%	—	理想值約 95%

AR(1) 的 RMSE 比 Naive 低 0.35%。

圖 12　網頁「評估」分頁：AR 與 Naive 的指標比較（對數價格）



圖 13　預測圖：歷史價格、測試期一步預測（橘）與未來 20 日預測（綠），色帶為 95% 預測區間



圖 14　測試期放大：深色帶 = 95% 信賴區間（平均值）、淺色帶 = 95% 預測區間（單日價格）

評估指標：AR(10) vs Naive baseline（測試期 243 天，一步預測）

指標	AR(10)	Naive（明天 = 今天）	說明
MAE	30.395	30.802	平均絕對誤差
MSE	1,701	1,756	均方誤差
RMSE	41.247	41.908	與價格同單位
MAPE	1.51%	1.53%	平均絕對百分比誤差
R^2	0.9886	0.9882	價格水準的 R^2 通常很高，需與 Naive 比較才有意義
漲跌方向準確率	58.5%	—	50% 約等於擲硬幣
95% PI 涵蓋率	63.8%	—	理想值約 95%

AR(10) 的 RMSE 比 Naive 低 1.58%。預測區間涵蓋率（63.8%）明顯低於 95%：測試期的波動比訓練期大，可在左側把「建模尺度」改成對數價格試試。

圖 15　對照：改用原始價格建模時，95% 預測區間涵蓋率只有約 64%

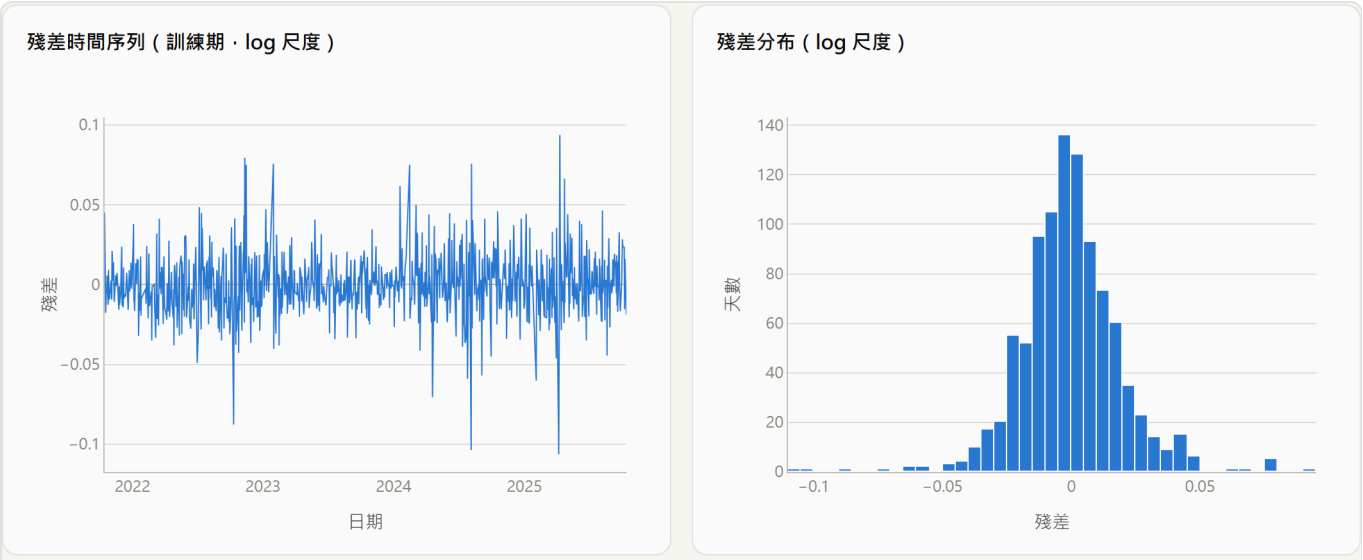


圖 16　訓練期殘差的時間序列與分布（log 尺度）



圖 17　殘差自我相關與 Ljung-Box 檢定

3.6 Deployment 部署

以全部資料重新估計 AR(1) 後遞迴預測未來 20 個交易日。第 2 天以後要用預測值當作落後值，誤差會累積，因此預測區間越來越寬。內建資料到 2026-10-14 為止，所以預測從下一個交易日開始；下表列出前 10 天，完整 20 天可在網頁下載 CSV。若在網頁用股票代號重新下載，會以最新資料預測。

日期	預測收盤價	95% PI 下限	95% PI 上限
2026-10-15	2,495.2	2,402.1	2,592.0
2026-10-16	2,500.4	2,369.4	2,638.7
2026-10-19	2,505.7	2,345.8	2,676.5
2026-10-20	2,510.9	2,326.7	2,709.7
2026-10-21	2,516.2	2,310.7	2,740.1
2026-10-22	2,521.5	2,296.7	2,768.3
2026-10-23	2,526.8	2,284.3	2,795.1
2026-10-26	2,532.1	2,273.1	2,820.7
2026-10-27	2,537.5	2,262.9	2,845.4
2026-10-28	2,542.8	2,253.6	2,869.2



圖 18　網頁「部署」分頁：未來 20 個交易日預測與 95% 預測區間

- **網站**：Vercel（https://aiot-hw2-regression.vercel.app）與 GitHub Pages（https://jua91352.github.io/AIoT-HW2-Regression/），推送到 GitHub 後自動重新部署。
- **架構**：純前端 HTML + JavaScript（統計計算在瀏覽器完成），Vercel Serverless Function `api/stock.js` 代理 Yahoo Finance 股價；詳見 `design.md`。
- **使用**：預測結果可下載成 CSV；網頁支援手機瀏覽與深色模式。



圖 19　手機版畫面

股價接近隨機漫步，本模型僅供課堂學習線性回歸與時間序列，不構成任何投資建議。

四、可任意輸入資料（加分項）

使用者不需修改程式，就能在側邊欄更換資料來源：

方式	說明	示範
範例資料	台積電 2330.TW（內建）、Apple AAPL（plotly 公開資料）	本報告第三章
股票代號	輸入任何 Yahoo Finance 代號，台股加 .TW / .TWO，可選 1～10 年	元大台灣50 0050.TW（圖 20）
CSV 網址	任何含日期與數值欄位的公開 CSV；GitHub 頁面網址自動轉 raw	plotly finance-charts-apple.csv（圖 21）
上傳檔案	CSV 只在瀏覽器處理，不會上傳伺服器	—

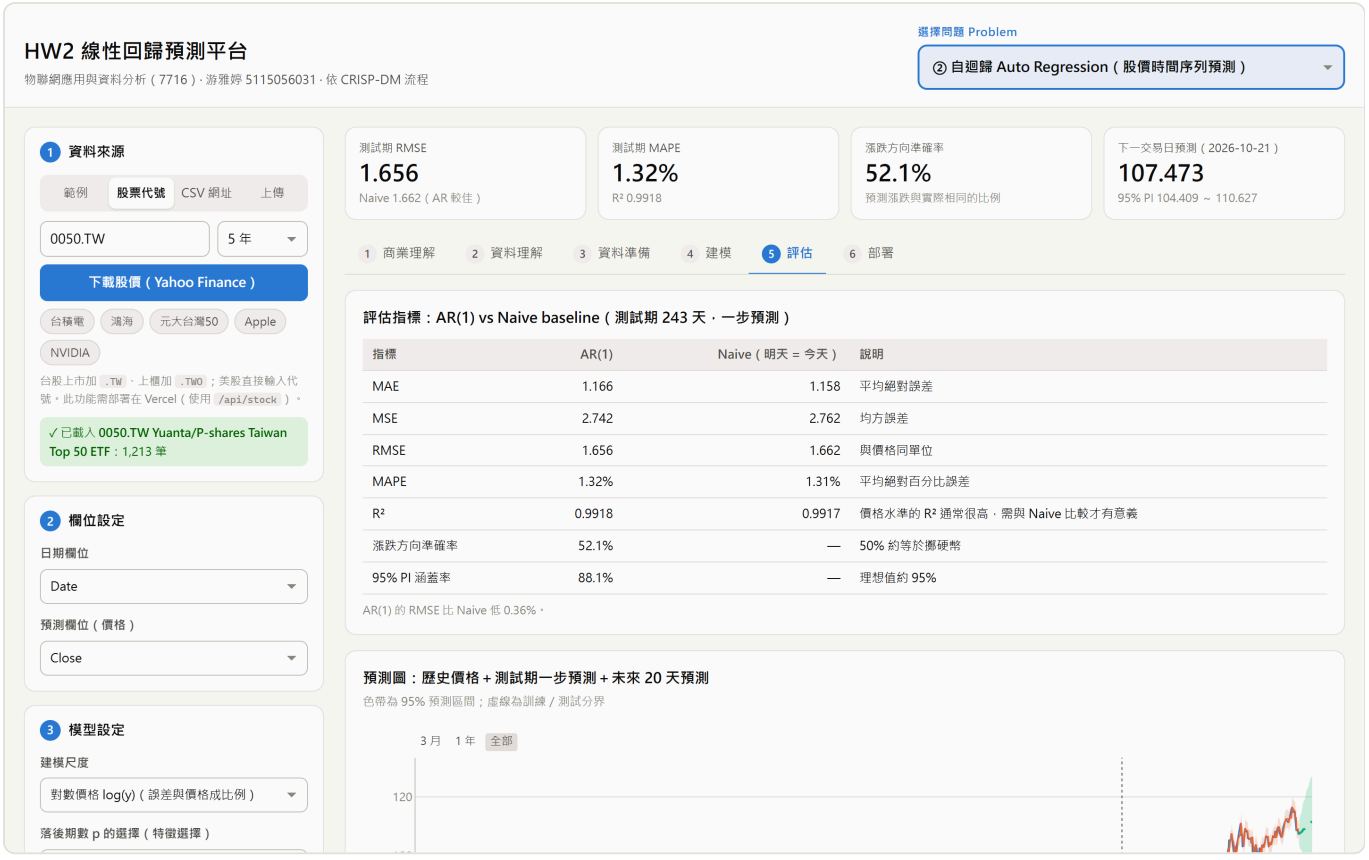


圖 20　輸入股票代號 0050.TW 後自動下載並重新建模

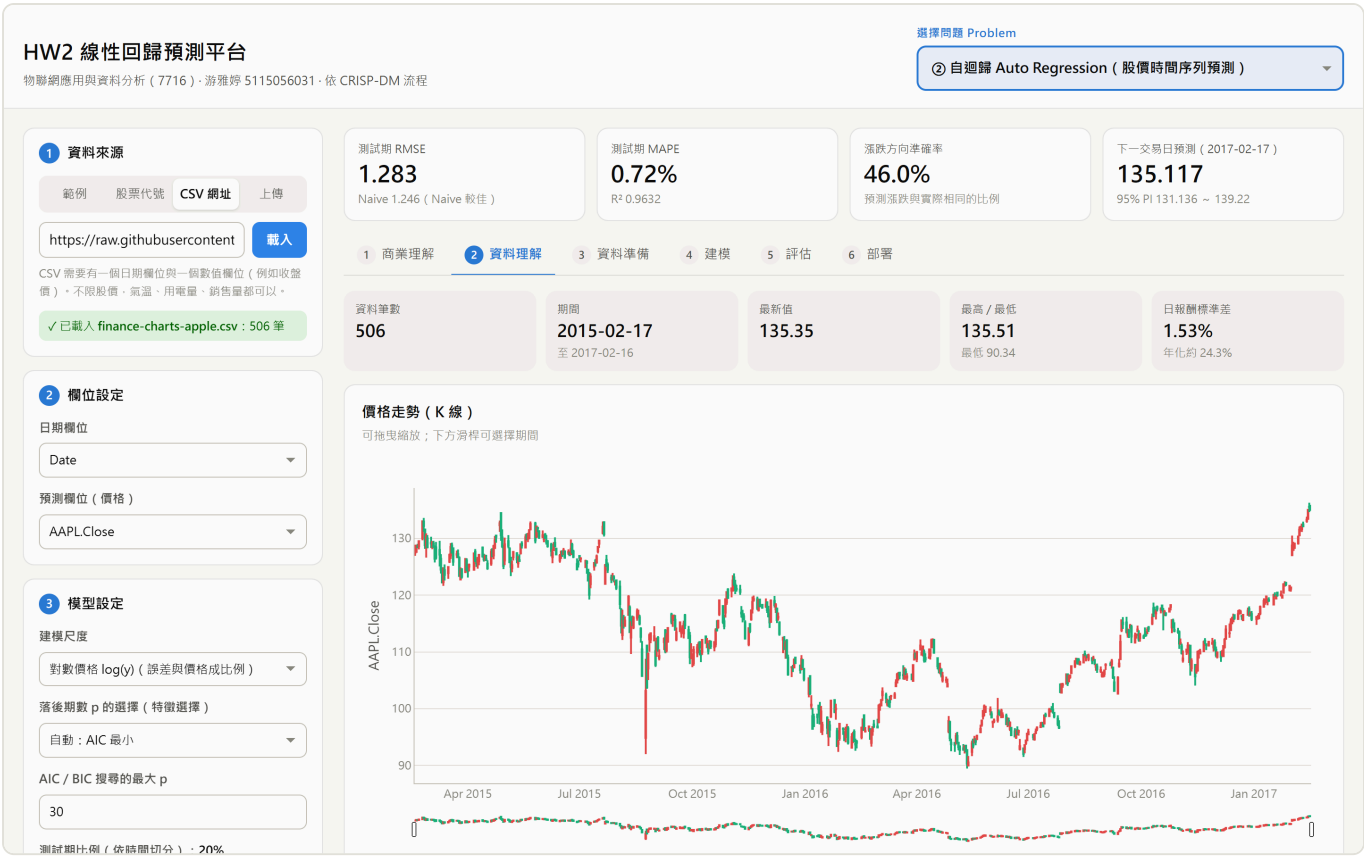


圖 21　貼上 Apple 股價 CSV 網址，自動辨識日期與收盤價欄位

問題 ① 也可輸入任意 CSV 網址。以老師指定的 50_Startups 為例（圖 22），系統自動把 State 做 one-hot、以交叉驗證選出 2 個特徵（R&D Spend、Marketing Spend），測試集 $R^2 = 0.9464$；係數為 R&D Spend 0.8145、Marketing Spend 0.02474。



圖 22　問題 ①：貼上 50_Startups.csv 網址即可完成特徵選擇與建模

五、問題 ①：多元線性回歸（簡述，詳見 DIC2）

資料集為 Kaggle Playground Series S4E5「Predict the Flood」（https://www.kaggle.com/competitions/playground-series-s4e5），20 個洪水風險因子預測洪水機率，符合「特徵 > 13」的要求；網頁使用訓練集隨機抽樣 20,000 筆，訓練 / 測試 = 16,000 / 4,000。

特徵選擇方法	類型	CV 最佳 k	前 3 名特徵	計算時間
SelectKBest（F 檢定）	Filter 過濾法	20	TopographyDrainage、MonsoonIntensity、DamsQuality…	15 ms
RFE 遞迴特徵消除	Wrapper 包裝法	20	TopographyDrainage、MonsoonIntensity、RiverManagement…	49 ms
Forward Selection 前向逐步選擇	Wrapper 包裝法	20	TopographyDrainage、MonsoonIntensity、RiverManagement…	56 ms
Lasso（L1 正則化）	Embedded 嵌入法	20	TopographyDrainage、MonsoonIntensity、DamsQuality…	39 ms

四種方法都選出全部 20 個特徵：每個特徵與目標的相關係數都只有 0.162 ~ 0.197、標準化係數幾乎相同，缺一不可（只用 5 個特徵時測試 R^2 僅 0.177）。OLS 測試集 R^2 = 0.8434、RMSE = 0.02003，95% 預測區間涵蓋率 94.75%。

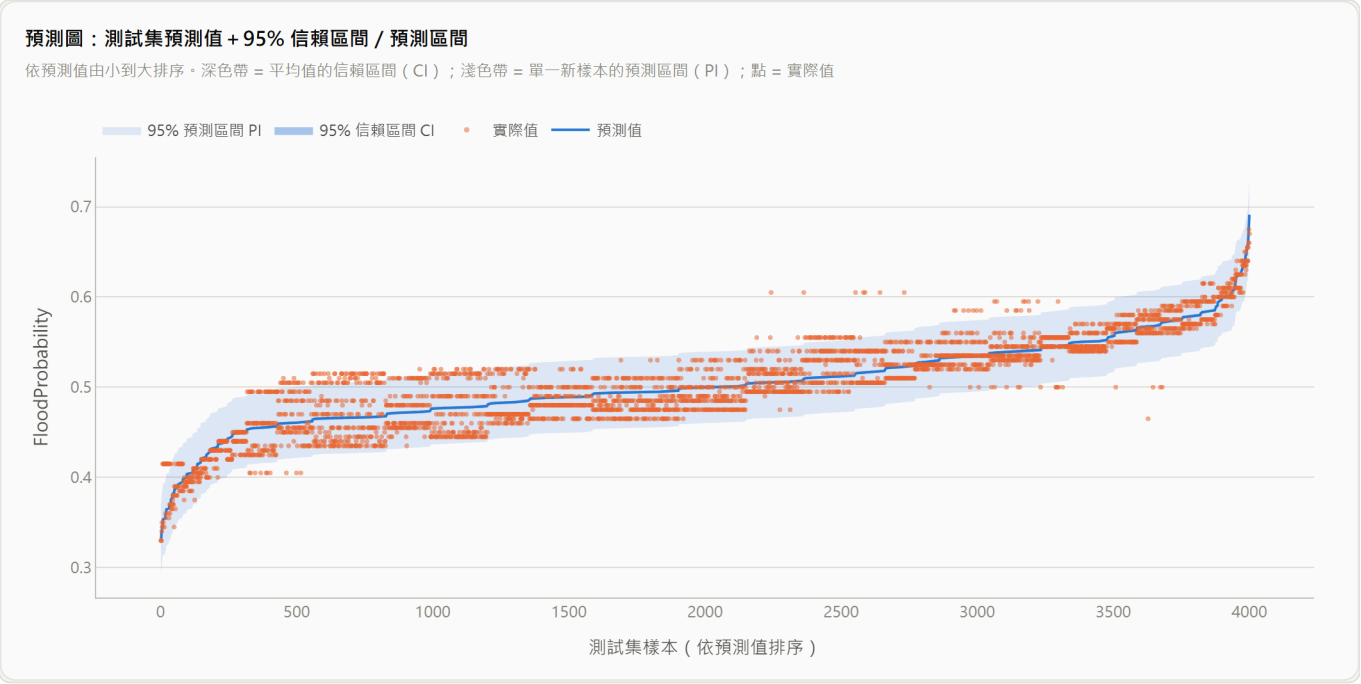


圖 23　問題 ① 測試集預測圖 + 95% 信賴區間 / 預測區間

5.1 NotebookLM 摘要 Kaggle 洪水預測的同主題解法

以 NotebookLM 研究網路上 Kaggle Playground Series S4E5（Predict the Flood）的同主題解法，摘要如下：

> 在 Kaggle S4E5 洪水預測競賽中，單純多元線性回歸展現出驚人的基準表現，因目標值主要由特徵總和決定，僅靠線性擬合即可達到 0.845 的 R^2 分數，優於未經特徵工程的原始樹狀模型；但其限制在於無法捕捉細微的非線性殘差與交互作用，導致分數到達瓶頸。社群隨後發現此資料結構，開發出關鍵的列級特徵工程，包含計算特徵總和（fsum）、按數值大小對列特徵進行排序，以及計算列標準差、極值與高於閾值的特徵數量等統計量。
>
> 前幾名優勝解法進一步結合 CatBoost、XGBoost、LightGBM 與 AutoGluon 等多元模型，並利用 Ridge 或 Lasso 回歸對多組折外預測（OOF）進行加權集成，成功將 R^2 分數提升至 0.869 以上。這給予使用多元線性回歸的學生重要啟示：線性模型是快速驗證全局規律與建立強大 Baseline 的優良起點，但若要達到極致預測精度，仍需深入進行 EDA，結合列統計特徵開發與多模型集成，才能補足單一線性模型的侷限。

六、主流解法比較

6.1 股價預測（問題 ②）

方法	做法	與本作業的關係
Naive / 隨機漫步	明天價格 = 今天價格	股價預測的標準基準；本作業 AR(1) 只略優於它
AR / ARIMA（Box-Jenkins）	以落後值（及差分、移動平均項）建模	本作業採用 AR(p)，以 AIC / BIC 選階數
GARCH 類模型	讓誤差變異數隨時間變化	可改善波動度變大時預測區間偏窄的問題（3.5 節）
機器學習（LSTM、XGBoost 等）	以大量技術指標或序列特徵訓練非線性模型	網路上常見，但樣本外常難以穩定贏過 Naive；超出「線性回歸」範圍

本作業的結果（$\varphi_1 \approx 1$、RMSE 與 Naive 幾乎相同）與效率市場假說的看法一致：只用過去價格很難預測明天的漲跌；線性模型的價值在於提供可解釋的基準與合理的預測區間。

6.2 Kaggle 洪水預測（問題 ①）

模型	類型	R^2
本平台：MLR（OLS，瀏覽器，抽樣 20,000 筆）	線性	0.8434
MLR（OLS，20 個特徵）	線性	0.8449
MLR + 列統計特徵工程	線性	0.8658
HistGradientBoosting（原始特徵）	樹模型	0.8355
HistGradientBoosting + 特徵工程	樹模型	0.8689
Kaggle 前幾名（CatBoost / XGBoost / LightGBM 集成）	集成	≈ 0.869

Python 版數據取自 1014 版分析（Kaggle 全部 1,117,957 筆，20% holdout）。線性模型已達 0.845，加入列統計特徵或樹模型集成可再提升到約 0.869。

七、NotebookLM 摘要 股價預測的同主題解法

使用 NotebookLM 研究網路上以時間序列預測股價的同主題解法，請它比較主流方法、說明 AR 為何難以贏過 Naive，並給出建議。摘要如下（保留原文，只把公式改為一般寫法）：

> 以下為您整理的時間序列股價預測主流方法比較與分析摘要：
>
> **1. 主流預測方法比較**
>
> - **Naive / 隨機漫步基準**：做法為假設明日股價等於今日股價 ($\hat{Y}_{t+1} = Y_t$)。優點是極簡且零參數，完全無過擬合風險；缺點是無法預測趨勢轉折或波幅。
> - **AR / ARIMA**：利用歷史價格（自迴歸 AR）與殘差（移動平均 MA）捕獲線性規律。優點是理論完備、適合平穩序列；缺點是無法處理非線性動態，面對非平穩股價易退化。
> - **GARCH**：針對條件變異數建模，專注於捕捉金融市場的「波動聚集（Volatility Clustering）」現象。優點是精準評估風險與波動度，缺點是其預測標的為波動率而非價格方向。
> - **LSTM (機器學習)**：透過門控機制學習非線性長短期依賴。優點是擬合能力強；缺點是需要大量數據、容易過擬合高噪音股價、模型為黑盒子且常見預測滯後（Lagging）。
>
> **2. 為什麼 AR 很難贏過 Naive 基準？**
>
> 根據效率市場假說（EMH），股價價格序列近似隨機漫步，其報酬率自相關性極低且高噪音。若直接對非平穩的原始股價建立 AR 模型，參數會趨近於 1，實際退化為 Naive 模型；若對差分後的平穩報酬率建模，由於信躁比極低，估計出的 AR 參數多為樣本雜訊（過擬合），使得樣本外（Out-of-Sample）預測誤差往往大於零參數的 Naive 基準。
>
> **3. 給用「線性回歸」預測股價學生的建議**
>
> 1. **切勿直接預測原始股價**：原始股價是非平穩序列，直接做 OLS 迴歸會產生「偽迴歸（Spurious Regression）」及虛高 R^2 的假象。
> 2. **改為預測「報酬率」或「漲跌方向」**：將數據轉換為平穩序列後，再結合技術指標或總體經濟特徵進行預測。
> 3. **務必以 Naive Model 為對照組**：採用滾動式樣本外驗證（Rolling Walk-Forward），並比較其 RMSE/MAE 是否真的擊敗簡單的 Naive Baseline。

7.2 與本作業結果的對照

NotebookLM 摘要的論點	本作業的結果
對非平穩股價建立 AR 模型，參數會趨近 1、退化為 Naive	AR(1) 的 $\varphi_1 = 1.0006$（95% CI 0.9969 ~ 1.0044，涵蓋 1）；測試期 RMSE 41.762，與 Naive 的 41.908 幾乎相同，完全吻合。對數價格的一階差分就是報酬率，$\varphi_1 \approx 1$ 代表報酬率接近白噪音（Ljung-Box p = 0.190）
直接預測原始股價會出現偽迴歸與虛高的 R^2	訓練期 $R^2 = 0.9965$、測試期 $R^2 = 0.9883$ 都很高，但 Naive 的 R^2 也有 0.9882；因此本報告以 Naive 為主要比較基準，不以 R^2 判斷模型好壞
GARCH 能捕捉「波動聚集」、評估風險	原始價格模型的 95% 預測區間涵蓋率只有 63.8%；改用對數價格後為 94.2%，但換成 0050.TW 仍只有約 88%，顯示波動度會隨時間改變，GARCH 類模型是下一步
務必以 Naive 為對照組，並採滾動式樣本外驗證	本作業已以 Naive 為對照組，並依時間切分、每天用真實歷史值做一步預測；尚未做多個起點的滾動驗證，列為未來改進
改為預測報酬率或漲跌方向	網頁已計算漲跌方向準確率（52.8%，接近擲硬幣）；以報酬率為目標並加入技術指標的模型列為未來改進

八、GPT 輔助內容 AI 協助說明

本作業使用 AI 助理 **Claude Code（Anthropic Claude）**協助完成。完整對話過程已匯出為 PDF（`5115056031_hw2_AI對話紀錄.pdf`），另行上傳至 iLearning。

項目	由誰決定 / 完成
作業需求解讀（讀取 iLearning 作業頁與 Notion 補充）	AI 讀取整理，學生確認
不使用 Streamlit，改為可部署到 GitHub / Vercel 的純前端網頁	學生決定
兩種 problem 的設計（多元線性回歸 + 課堂教的股價自迴歸）	AI 提案，學生採用
統計核心、網頁介面、圖表、股價 API 的程式碼	AI 撰寫
數值正確性驗證（與 Python statsmodels 對照）	AI 執行
部署方式（GitHub + Vercel）與 repo 名稱	學生決定
依最新作業需求複查、決定報告以自迴歸為主	學生決定
本報告書、design.md、資訊圖表	AI 依網頁實際執行結果撰寫，學生審閱

九、數值正確性驗證

統計方法全部以 JavaScript 自行實作，因此逐項與 Python statsmodels 對照：

項目	測試資料	結果
AR(3) 係數與 5 步預測區間	台積電 2330.TW 收盤價	與 `AutoReg(...).get_prediction()` 一致
OLS 係數、標準誤、p 值、R^2、F、AIC、BIC	50_Startups 全資料（含 State one-hot）	完全一致
新資料點的信賴區間與預測區間	同上	一致（小數點後 3 位內）
Durbin-Watson、Jarque-Bera、Breusch-Pagan、RESET	同上	一致

十、結論與限制

- 以 AIC / BIC 選出的 AR(1) 模型 $\varphi_1 \approx 1.0006$，台積電股價接近隨機漫步；測試期 RMSE 41.762 僅略優於 Naive 的 41.908。
- 建模尺度對不確定性影響很大：對數價格讓 95% 預測區間涵蓋率從 63.8% 提升到 94.2%。
- 平台滿足兩個加分項：下拉選單切換兩種問題、可任意更換資料來源（股票代號、CSV 網址、上傳）。
- **限制**：AR 假設誤差變異數固定，市場波動度改變時預測區間仍會失準（例如 0050.TW 的涵蓋率為 88%）；未來日期只排除週末、未扣除國定假日；外部 CSV 需允許跨網域讀取。
- **未來改進**：依 NotebookLM 摘要的建議，改以報酬率或漲跌方向為預測目標、採滾動式樣本外驗證（Rolling Walk-Forward），並加入 GARCH 波動度模型與成交量等外生變數（ARX）。

參考資料

1. Yahoo Finance，2330.TW 歷史股價：https://finance.yahoo.com/quote/2330.TW/history
2. Kaggle Playground Series S4E5：https://www.kaggle.com/competitions/playground-series-s4e5
3. 50_Startups 資料集：https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv
4. statsmodels：AutoReg、OLS 文件 https://www.statsmodels.org/
5. 網頁使用的函式庫：Plotly.js、PapaParse、jStat